

SVEUČILIŠTE U ZAGREBU  
**FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA**

ZAVRŠNI RAD br. 1936

**ANALIZA TRENINGA KOŠARKE PUTEM  
MOBILNE APLIKACIJE**

Vedran Kumanović

Zagreb, lipanj, 2025.

SVEUČILIŠTE U ZAGREBU  
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

Zagreb, 3. ožujka 2025.

ZAVRŠNI ZADATAK br. 1936

Pristupnik: **Vedran Kumanović (1191247427)**

Studij: Elektrotehnika i informacijska tehnologija i Računarstvo

Modul: Računarstvo

Mentor: izv. prof. dr. sc. Matko Orsag

Zadatak: **Analiza treninga košarke putem mobilne aplikacije**

Opis zadatka:

Cilj ovog rada je razviti mobilnu aplikaciju za analizu i poboljšanje košarkaškog treninga te istražiti mogućnosti primjene postojećih i razvoj novih perifernih uređaja povezanih putem Bluetooth tehnologije. Aplikacija će omogućiti prikupljanje i analizu podataka o igračevim performansama, poput preciznosti šuta i kretanja na terenu. Istražit će se mogućnosti integracije s pametnim senzorima, nosivim uređajima i drugim Bluetooth dodacima kako bi se poboljšala interaktivnost i preciznost mjerjenja.

Rok za predaju rada: 23. lipnja 2025.

*Hvala svima koji su mi pomogli u radu na ovom završnom radu.*

# Sadržaj

|  |    |
|--|----|
| <b>1. Uvod</b>   | 3  |
| <b>2. Teorijska podloga i dosadašnja istraživanja</b>            | 5  |
| 2.1. Umjetne neuronske mreže                                     | 5  |
| 2.1.1. Višeslojni perceptron                                     | 6  |
| 2.1.2. Konvolucijske neuronske mreže                             | 7  |
| 2.2. Detekcija objekata  | 9  |
| 2.2.1. Dvostupanjske metode detekcije objekata                   | 9  |
| 2.2.2. Jednostupanjske metode detekcije objekata                 | 10 |
| 2.3. Dosadašnja istraživanja                                     | 11 |
| <b>3. Korištene tehnologije i alati</b>                          | 13 |
| <b>4. Razvoj sustava za detekciju i analizu košarkaškog šuta</b> | 15 |
| 4.1. Prikupljanje i obrada podataka                              | 15 |
| 4.2. Detekcija objekata korištenjem YOLO modela                  | 16 |
| 4.3. Prepoznavanje pokušaja šuta i pogodjenih koševa             | 18 |
| 4.4. Rekonstrukcija 2D i 3D putanje lopte                        | 19 |
| 4.5. Određivanje kuta izbačaja i brzine šuta                     | 23 |
| 4.6. Mogućnosti prijenosa sustava na mobilne uređaje             | 23 |
| <b>5. Rezultati i rasprava</b>                                   | 24 |
| 5.1. Primjeri detekcije i analize šuteva                         | 24 |
| 5.2. Evaluacija točnosti detekcije i analize                     | 24 |
| 5.2.1. Eksperimenti u kojima se razvijeni postupak dobro ponaša  | 24 |

|   |           |
|---|-----------|
| 5.2.2. Eksperimenti u kojima postupak nalazi objekte koje nismo tražili<br>(false positive error) . . . . . | 24        |
| 5.2.3. Eksperimenti u kojima postupak ne pronađe tražene objekte (false<br>negative error) . . . . .        | 24        |
| <b>6. Zaključak . . . . .</b>   | <b>25</b> |
| <b>Literatura . . . . .</b>   | <b>26</b> |
| <b>Sažetak . . . . .</b>  | <b>29</b> |
| <b>Abstract . . . . .</b>   | <b>30</b> |
| <b>A: The Code . . . . .</b>  | <b>31</b> |

## 1. Uvod

Osnovni cilj košarkaške igre je stvaranje prilika za poentiranje, pri čemu svi elementi individualne tehnike, timske suradnje i kolektivne taktike nastoje omogućiti igraču da dođe u što povoljniju poziciju za šut. Brojna istraživanja pokazala su da učinkovitost šuta, posebice u ključnim trenucima utakmice i s različitih pozicija na terenu, u značajnoj mjeri određuje ishod susreta. Primjerice, u analizama utakmica hrvatske lige pokazano je da slobodna bacanja u posljednjih pet minuta čine u prosjeku 42% poena pobjedničkih ekipa u tijesnim završnicama, u usporedbi s tek 22% kod poraženih [1]. Osim toga, dokazano je da je konačni rezultat utakmice snažno povezan s preciznošću šutiranja s distance, ali i s realizacijom šuteva iz reketa, poput polaganja i zakucavanja [2]. Bez efikasnog poentiranja, svi ostali tehničko-taktički aspekti igre gube smisao.

S obzirom na ova saznanja, jasno je da preciznost šuta, kako iz igre tako i s linije slobodnog bacanja, igra presudnu ulogu u konačnom ishodu košarkaških utakmica. Intenzivan i ponavljajući samostalni trening neophodan je za napredak u šutu, no mnogim igračima nedostaje mogućnost objektivne analize vlastite tehnike. Analize šuterske učinkovitosti te biomehanike izvedbe u većini trenažnih procesa još uvijek se uvelike oslanjaju na subjektivne dojmove trenera i ručne statistike. Takav pristup često je spor, sklon pogreškama i ne omogućuje dublju, kvantitativnu analizu specifičnih šuterskih situacija, kao što su kut i brzina izbačaja lopte.

Cilj ovog rada je razvoj sustava za automatsku analizu šuterske izvedbe u košarci korištenjem računalnog vida i dubinskih kamera. Sustav omogućuje precizno praćenje 3D putanje lopte, detekciju koša te izračun ključnih metrika poput kuta izbačaja, brzine lopte i uspješnosti šuta. Takva analiza pruža trenerima i igračima objektivne informacije potrebne za optimizaciju trenažnog procesa i povećanje učinkovitosti.

Za detekciju lopte i obruča koristi se YOLO model treniran na vlastitom skupu podataka, dok se 3D pozicije objekata dobivaju kombiniranjem 2D koordinata s dubinskim informacijama. Razvijeni sustav predstavlja korak prema modernizaciji trenažnog procesa u košarci, omogućujući preciznu, automatiziranu i pristupačnu analizu šuta, s ciljem poboljšanja individualne izvedbe i ukupne uspješnosti momčadi.

## **2. Teorijska podloga i dosadašnja istraživanja**

### **2.1. Umjetne neuronske mreže**

Duboko učenje temelji se na sposobnosti neuronskih mreža da aproksimiraju složene nelinearne funkcije, što omogućuje njihovu primjenu u širokom spektru problema [3]. Ključni model koji se koristi za tu svrhu je višeslojni perceptron (eng. multilayer perceptron (MLP)), koji kroz višeslojne arhitekture modelira odnose između ulaza i željenih izlaza.

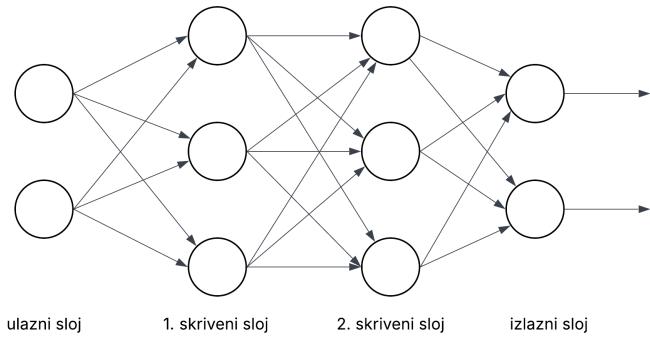
Za uspješno treniranje takvih mreža nužno je koristiti tehnike poput regularizacije (za sprječavanje prenaučenosti) i optimizacijskih algoritama (poput varijanti gradijentnog spusta). Kada se modeli primjenjuju na velike ulaze, primjerice slike visoke rezolucije ili vremenske nizove, koriste se specijalizirane arhitekture:

- **Konvolucijske neuronske mreže (CNN)** – dizajnirane za obradu vizualnih podataka, koriste konvolucijske slojeve za automatsko prepoznavanje značajki u slikama.
- **Rekurentne neuronske mreže (RNN)** – koriste se za sekvencialne podatke, poput teksta ili vremenskih nizova, jer mogu modelirati vremensku ovisnost između podataka.

Ove arhitekture čine temelj za mnoge praktične primjene dubokog učenja, uključujući analizu videozapisa, detekciju objekata i biomehaničku analizu pokreta, što je izravno povezano s temom ovog rada.

### 2.1.1. Višeslojni perceptron

Duboke unaprijedne mreže (eng. deep feedforward networks), poznate i kao višeslojni perceptroni (MLP – Multilayer Perceptrons), predstavljaju jedan od najvažnijih modela dubokog učenja. Njihov osnovni cilj je aproksimacija nepoznate funkcije  $f^*$ , koja opisuje odnos između ulaznih podataka  $x$  i željenog izlaza  $y$ , odnosno  $y=f^*(x)$ . Riječ je o vrsti umjetne neuronske mreže sastavljene od niza slojeva međusobno povezanih neuronskih jedinica (perceptrona) 2.1. Ove mreže nazivamo unaprijednim jer se informacije kroz mrežu kreću samo u jednom smjeru, od ulaza prema izlazu, kroz niz skrivenih slojeva i nelinearnih transformacija. Nema povratnih veza između slojeva, za razliku od reku-rentnih neuronskih mreža (RNN), kod kojih izlazi mogu ponovno ulaziti u mrežu i time modelirati vremensku ovisnost [3].



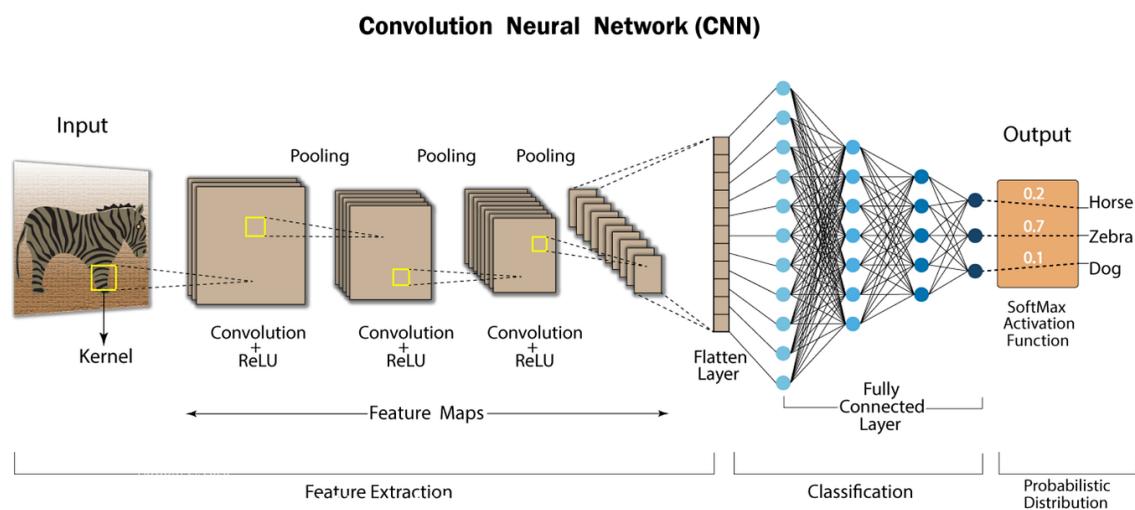
**Slika 2.1.** Unaprijedna slojevita neuronska mreža  $2 \times 3 \times 3 \times 2$  [4]

Da bismo povećali ekspresivnost mreže i omogućili joj modeliranje nelinearnih odnosa, korišteni neuroni moraju imati prijenosne funkcije koje su nelinearne. U unaprijednim neuronskim mrežama do nedavno je bilo uobičajeno koristiti sigmoidalne prijenosne funkcije, dok se danas se za to preferira uporaba ReLU jer omogućava treniranje dubljih mreža (s većim brojem slojeva) [5].

Treniranje MLP mreže provodi se metodom nadziranog učenja, gdje je poznat skup ulazno-izlaznih parova. Učenje neuronskih mreža provodi se pomoću postupka propagacije pogreške unatrag (engl. Error Backpropagation), koji omogućuje učinkovit izračun svih parcijalnih derivacija te njihovu primjenu pri određivanju veličine korekcije svake od težina u mreži [5].

## 2.1.2. Konvolucijske neuronske mreže

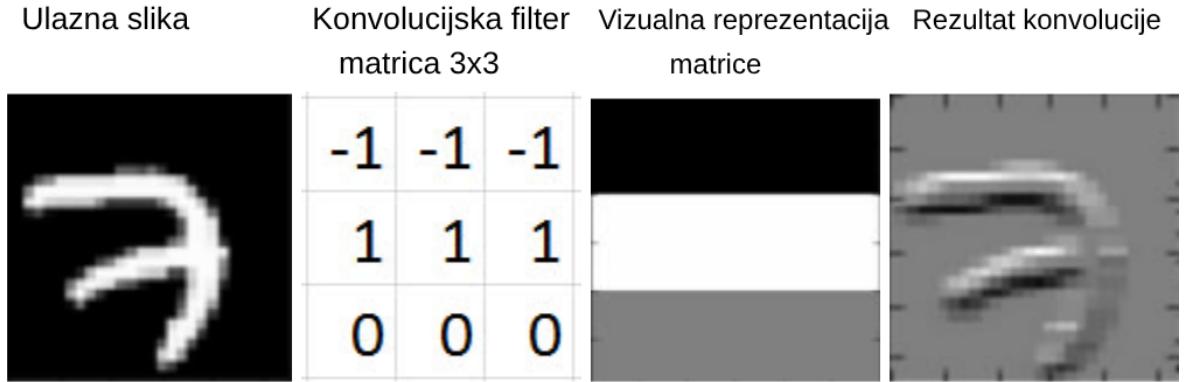
Konvolucijske neuronske mreže (eng. Convolutional Neural Networks - CNN) specijalizirane su vrste neuronskih mreža za obradu podataka koje imaju topologiju nalik na rešetku. Za razliku od višeslojnih perceptronova, gdje su svi neuroni u sloju povezani sa svim neuronima u prethodnom sloju, CNN koristi lokalne veze i dijeljenje težina, čime se značajno smanjuje broj parametara i bolje iskorištava prostorna struktura podataka [3].



Slika 2.2. Arhitektura konvolucijske neuronske mreže [6]

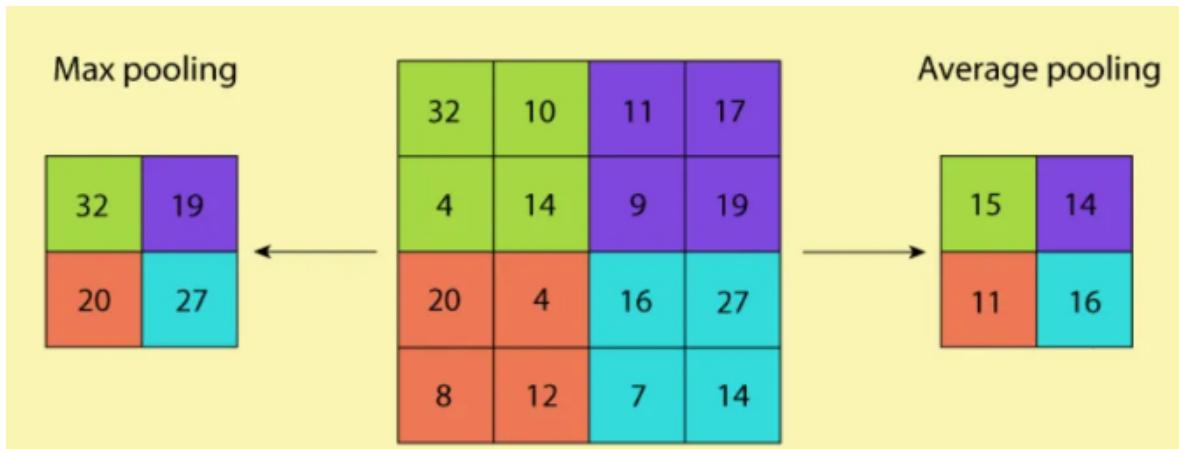
Arhitektura CNN-a, prikazana na slici 2.2., tipično se sastoji od:

- **Konvolucijskih slojeva** – provode operaciju konvolucije nad slikom, pri čemu se filter (jezgra, eng. kernel) sustavno primjenjuje na različite dijelove slike kako bi se prepoznali specifični uzorci ili značajke. Ilustrativni primjer konvolucije možemo vidjeti na slici 2.3. Ulazna slika predstavlja kadar iz videozapisa, konvolucijski filter je matrica vrijednosti koja se pomiče preko slike, a rezultat konvolucije je nova slika koja sadrži informacije o lokalnim značajkama ulazne slike.



**Slika 2.3.** Primjer konvolucijske operacije koji prepoznaje rubove, najslijepetiji pikseli označavaju detektirani rub [7]

- **Slojeva sažimanja (pooling)** – odgovoran je za smanjenje prostorne dimensionalnosti mapa značajki koje su proizvedene konvolucijskim slojevima (slika 2.4.).



**Slika 2.4.** Sloj sažimanja, koristi  $2 \times 2$  matricu [6]

- **Aktivacijskih slojeva** – primjenjuje nelinearnu prijenosnu funkciju na izlaz prethodnog sloja, uobičajeno funkcija ReLU opisana formulom 2.1:

$$ReLU(x) = \max(0, x) \quad (2.1)$$

- **Potpuno povezanih slojeva** – predstavlja klasični sloj umjetnih neuronskih mreža u kojem je svaki neuron povezan sa svim neuronima prethodnog sloja.

Jedna od ključnih prednosti CNN-a je mogućnost hijerarhijskog učenja značajki. Početni slojevi otkrivaju osnovne strukture (npr. rubove), dok dublji slojevi uče složenije

apstrakcije (npr. oblike lopte, ruku ili koša). Upravo zbog toga, CNN modeli su osnova većine modernih sustava za računalni vid, uključujući detekciju objekata, segmentaciju slika i analizu videozapisa.

No ipak, njihova primjena dolazi s određenim izazovima. Treniranje zahtijeva značajne računalne resurse i velike količine podataka zbog složene arhitekture i velikog broja parametara. Osim toga, modeli su skloni prekomjernom učenju na malim skupovima podataka, a njihova interpretabilnost je ograničena jer je teško uvidjeti koje značajke mreža koristi prilikom donošenja odluka. Također, budući da su dizajnirani za podatke rešetkaste strukture, imaju ograničenu sposobnost obrade nepravilnih ili nestrukturiranih oblika.[3, 6].

## 2.2. Detekcija objekata

Detekcija objekata ključna je zadaća u računalnom vidu koja omogućuje klasifikaciju i lokalizaciju objekata unutar slike ili videozapisa. Za razliku od klasifikacije slike, koja određuje prisutnost objekta bez navođenja njegove lokacije, detekcija objekta pruža dodatne informacije o poziciji objekta putem koordinata ograničavajućih okvira (bounding boxes) [8].

Metode detekcije objekata mogu se podijeliti u dvije osnovne klase: jednostupanjske (eng. one-stage) i dvostupanjske (eng. two-stage) metode. Dvostupanjske metode detekcije najprije izdvajaju potencijalne regije s objektima, a zatim ih naknadno klasificiraju, dok jednostupanjski pristupi istovremeno obavljaju i lokalizaciju i klasifikaciju objekata. Glavna razlika između ova dva pristupa očituje se u brzini izvođenja – jednostupanjske metode su znatno brže. S druge strane, kada je riječ o preciznosti, obje kategorije postižu usporedive rezultate. U nastavku su detaljnije prikazane obje skupine metoda duboke detekcije objekata [9].

### 2.2.1. Dvostupanjske metode detekcije objekata

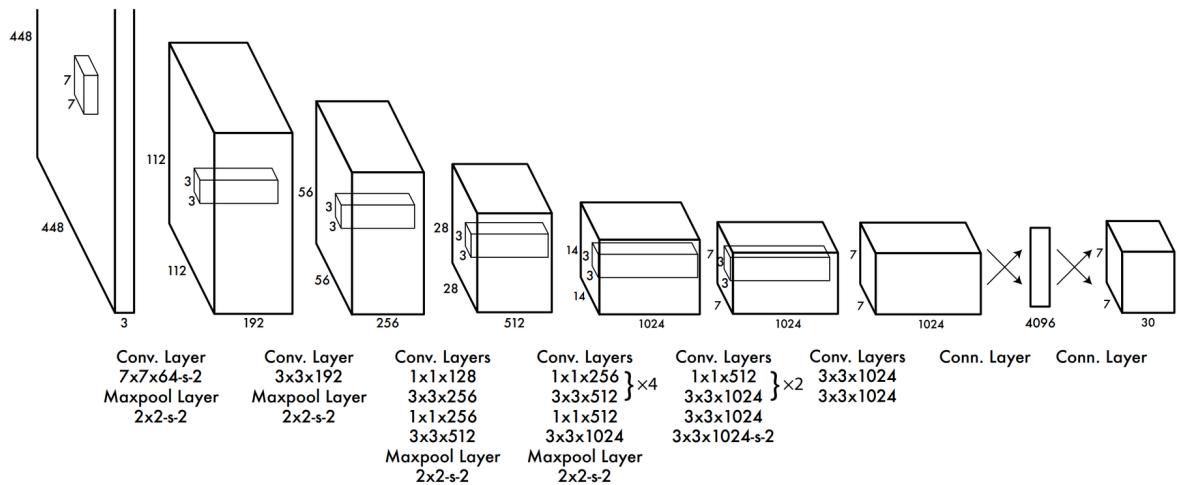
Dvostupanjski pristupi detekciji objekata obavljaju zadatak u više koraka. U prvom koraku, iz ulazne slike se izdvajaju potencijalne regije koje bi mogle sadržavati objekte. Nakon toga, za svaku od tih regija provodi se klasifikacija pomoću prethodno naučenog

klasifikatora, kojim se regije svrstavaju u odgovarajuće klase objekata. Prednost ovih metoda leži u tome što se klasifikacija provodi samo nad ograničenim brojem relevantnih prijedloga, čime se smanjuje utjecaj pozadine i povećava preciznost. Među najpoznatijim predstavnicima ovakvog pristupa su RCNN, SPPnet, Fast RCNN i Faster RCNN. RCNN modeli proširuju standardne konvolucijske mreže za potrebe detekcije i lokalizacije objekata, pri čemu kao izlaz daju skup bounding boxova za svaki detektirani objekt zajedno s pripadajućom klasom [8, 9].

### 2.2.2. Jednostupanjske metode detekcije objekata

Jednostupanjski algoritmi za detekciju objekata analiziraju cijelu sliku u jednom prolazu kroz mrežu te istovremeno predviđaju prisutnost i lokaciju objekata. Ovakav pristup značajno je učinkovit u pogledu računalnih resursa i brzine izvođenja, što ga čini pogodnim za primjenu u sustavima s ograničenim hardverskim kapacitetima i u stvarnom vremenu. Najpoznatije metode ovog tipa su: OverFeat, SSD, YOLO i RetinaNet.

Jedan od najpoznatijih predstavnika ove skupine i model koju ćemo mi koristiti je YOLO, koji koristi potpuno konvolucijsku neuronsku mrežu za istovremenu detekciju svih objekata na slici [8]. YOLO algoritam kao ulaz uzima cijelu sliku i koristi jednostavnu duboku konvolucijsku neuronsku mrežu za detekciju objekata. Struktura mreže temeljena je na CNN arhitekturi, koja se sastoji od konvolucijskih slojeva, slojeva sažimanja i potpuno povezanih slojeva (slika 2.5.).



Slika 2.5. Arhitektura CNN modela koji jetemelj za YOLO [8]

YOLO model dijeli ulaznu sliku na mrežu ćelija, pri čemu svaka ćelija predviđa odre-

đeni broj bounding boxova i pripadajućih vjerojatnosti za prisutnost objekta [10]. Svaka ćelija odgovorna je za detekciju objekata čiji centar leži unutar njezine granice. YOLO model koristi konvolucijske slojeve za ekstrakciju značajki iz slike, a zatim koristi potpuno povezane slojeve za generiranje predikcija[8]. Svaki granični okvir ima predviđanja u obliku ( $x, y, w, h, s$ ) gdje su ( $x, y$ ) koordinate okvira unutar ćelije, ( $w, h$ ) dimenzije graničnog okvira, a „ $s$ “ je pouzdanost da se objekt nalazi u okviru [9].

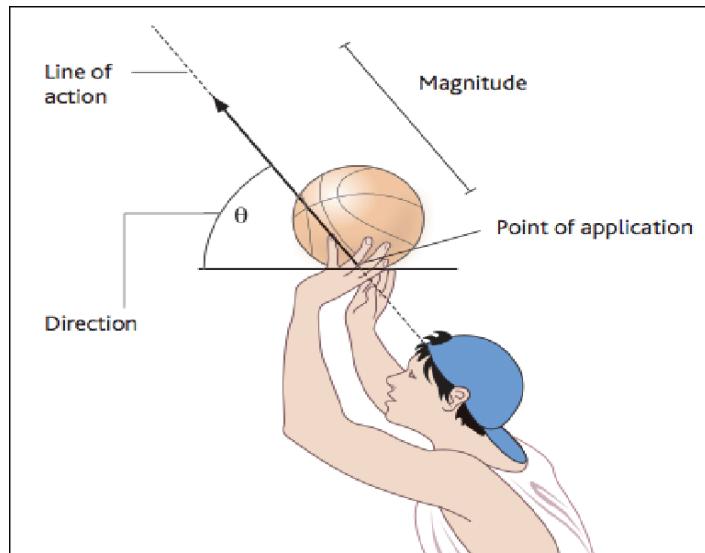
## 2.3. Dosadašnja istraživanja

Analiza učinkovitosti šuta u košarci predmet je brojnih istraživanja, kako iz tehničko-biomehaničkog, tako i iz tehnološkog aspekta. Neki radovi koriste napredne metode računalnog vida i dubokog učenja, dok se drugi oslanjaju na klasične biomehaničke pristupe.

Jedno suvremeno istraživanje temelji se na korištenju predtreniranog Faster R-CNN modela za detekciju lopte i obruča na videozapисima šuterskih pokušaja. Uz pomoć image segmentation tehnika i dvije metode aproksimacije parabole (Bounce-Around i SWISAC), analizira se 2D putanja lopte kako bi se izračunao kut izbačaja i predvidjelo hoće li lopta ući u koš. Iako model ne može detektirati loptu u trenutku kada prolazi kroz mrežicu zbog zaklonjenosti (occlusion), algoritam nudi predikciju pogotka na temelju projekcije parabole. Prednost ovakvog pristupa je mogućnost davanja automatskih povratnih informacija igraču o kutu izbačaja i točnosti šuta, no detekcija u zaklonjenim kadrovima ostaje izazov. Također, istraživanje ne uključuje 3D rekonstrukciju putanje lopte pa je potrebno postaviti kameru u optimalan položaj, okomito na liniju šuta, kako bi se dobili točni rezultati [11].

Drugi pristup koji se pokazao korisnim za analizu šuta, iako ne koristi računalni vid, jest biomehanički model koji uzima u obzir kut ubačaja lopte u koš, brzinu izbačaja, rotaciju i početnu visinu lopte. Slika 2.6. ilustrira četiri ključna svojstva sile za lakše razumijevanje biomehaničkih aspekata šuta. Istraživanje ističe kako manji kutovi izbačaja dovode do većih odstupanja od idealne putanje i smanjuju vjerojatnost uspješnog pogotka. Najveća pogreška ostvaruje se kod ulaznog kuta od  $90^\circ$ , dok se za kutove ispod  $50^\circ$  znatno smanjuje mogućnost pogotka. Također navodi kako su brzina izbačaja i kut izbačaja međusobno su povezani, pri čemu udaljenost šuta izravno utječe na brzinu iz-

bačaja, tj. što je šut udaljeniji, to je potrebna veća brzina. Udaljenost također neizravno utječe na kut izbačaja, preciznost šuta opada s većom udaljenošću jer i minimalna odstupanja postaju izraženija zbog duljeg vremena leta lopte. Rad pruža korisne smjernice za optimizaciju tehnike šuta s biomehaničkog aspekta, ali bez tehničke implementacije ili automatizirane analize [12].



**Slika 2.6.** Četiri osnovna svojstva sile: iznos (magnituda), smjer djelovanja, točka primjene i pravac djelovanja [12]

Još jedno istraživanje temeljilo se na teorijskoj analizi, gdje se proučavala putanja lopte prilikom šutiranja slobodnog bacanja. Analizirao se kut, brzina i rotacija pri ispuštanju. Analitički su izračunate kombinacije navedenih parametara koje su rezultirale uspješnim pokušajem. Optimalni ishod šuta postignut je pri kutu od oko  $60^\circ$  i brzinom od 7,3 m/s [13].

Sličan pristup primjenjen je u istraživanju [14], čiji je cilj bio utvrditi optimalne uvjete otpuštanja lopte pri slobodnom bacanju u muškoj košarci. Korišteno je stotine tisuća 3D simulacija putanja lopte, pri čemu je analizirano pet varijabli: visina otpuštanja, brzina otpuštanja, kut izbačaja, bočni kut i rotacija lopte. Pretpostavljen je da šuter postiže uspješnost od 70% i da lopta biva otpuštena na visini od 2,134 m. Rezultati su pokazali da šuter treba lopti dati do 3 Hz rotacije unazad, ciljati prema stražnjem dijelu obruča i izbaciti loptu pod kutom od  $52^\circ$  u odnosu na horizontalu. Također, preporučuje se što viši položaj otpuštanja lopte, pod uvjetom da to ne narušava konzistentnost izvođenja šuta.

### 3. Korištene tehnologije i alati

U sklopu ovog rada pažljivo su odabrane i implementirane različite tehnologije i alati koji su ključni za razvoj sustava za detekciju i analizu košarkaškog šuta.

Kao glavni programski jezik korišten je Python, zbog svoje čitljivosti, fleksibilnosti i velike podrške u području računalnog vida i dubokog učenja [15]. Za dohvat i obradu slike te implementaciju računalnog vida korištena je OpenCV biblioteka. Zahvaljujući svojoj modularnoj strukturi i širokoj podršci u zajednici, OpenCV omogućuje jednostavnu implementaciju zadataka poput obrade slika, filtriranja, praćenja objekata i vizualizacije rezultata [16]. U sklopu ovog projekta korišten je za obradu video okvira, crtanje bounding boxova, vizualizaciju putanje lopte te manipulaciju slikovnim i dubinskim podacima. Matplotlib poslužio je za grafički prikaz rezultata, posebno za crtanje i spremanje dijagrama putanje lopte i kuta izbačaja.

Snimanje videozapisa i dubinskih podataka vršeno je pomoću Oak-D Pro Wide kamere. Ova kamera opremljena je RGB senzorom visoke rezolucije i stereo kamerama za procjenu dubine. RGB podaci koristili su se za detekciju objekata, dok su dubinski podaci omogućili rekonstrukciju 3D putanje lopte. Osim mogućnosti snimanja slike, omogućuje istovremeno izvođenje detekcije objekata na samom uređaju, no taj pristup nije se pokazao dovoljnim, pa je taj dio obavljen na računalu [17].

Za pripremu skupa podataka korištena je platforma Roboflow, koja omogućuje jednostavno označavanje (anotaciju) objekata na slikama, organizaciju skupa podataka te automatsku generaciju formata kompatibilnih s različitim modelima računalnog vida [18]. U ovom radu, Roboflow je korišten za ručnu anotaciju položaja lopte i koša unutar slika dobivenih iz videozapisa šuteva.

Za detekciju objekata korištene su novije verzije YOLO modela, unaprijedene ver-

zija jednopravljnog detekcijskog algoritma (You Only Look Once), koji omogućuje brzo i precizno prepoznavanje objekata i segmentaciju slike. YOLO-ov jedinstveni pristup tretira detekciju objekata kao jedan regresijski problem, predviđajući okvire i vjerojatnosti klase izravno iz slike u jednom prolazu. YOLO podržava razne zadatke umjetne inteligencije vida kao što su detekcija, segmentacija, procjena položaja, praćenje i klasifikacija. Njegova najsuvremenija arhitektura osigurava vrhunsku brzinu i točnost, što ga čini prikladnim za različite primjene [19]. Za treniranje YOLO modela korišten je Google Colab, online razvojno okruženje koje omogućuje korištenje GPU-a u oblaku. Model je treniran na vlastitom skupu podataka snimljenom pomoću OAK-D kamere, a treniranje je provedeno u Colabu zbog jednostavnog pristupa računalnim resursima, lakog rukovanja podacima i brzine izvođenja, čime je omogućena brza iteracija modela i validacija rezultata.

## 4. Razvoj sustava za detekciju i analizu košarkaškog šuta

U ovom poglavlju opisan je postupak razvoja računalnog sustava za automatsku detekciju i analizu šuterskih izvedbi u košarci. Sustav kombinira metode računalnog vida, YOLO model za detekciju objekata, te obradu dubinskih i vremenskih podataka radi izračuna ključnih metrika poput putanje lopte, kuta izbačaja i brzine šuta.

### 4.1. Prikupljanje i obrada podataka

Prikupljanje podataka ključno je za treniranje i evaluaciju modela detekcije objekata. U ovom radu korišten je vlastiti skup podataka snimljen pomoću OAK-D Pro Wide kamere, koja omogućuje istovremeno snimanje RGB i dubinskih podataka.

Snimanje je provedeno u kontroliranim uvjetima, gdje su igrači izvodili šuteve iz različitih pozicija i sa različitim udaljenosti od koša. Također, fizičke predispozicije šutera, poput visine i tehnike izvođenja šuta, varirale su kako bi se obuhvatila široka paleta šuterskih situacija.

Nakon snimanja, videozapisi su obrađeni tako da su izdvojeni kadrovi koji sadrže šuterske pokušaje. Svaki kadar je potom ručno anotiran. Klase objekata koje su anotirane uključuju:

- **Košarkaška lopta u zraku** – označena kao *basketball*, predstavlja košarkašku loptu koja se detektira u kadru i ne dodiruje se s drugim objektima.
- **Košarkaška lopta u dodiru s košarkaškom mrežicom** - označena kao *ballnet*, predstavlja košarkašku loptu koja se detektira u kadru i dodiruje se s košarkaškom mrežicom.

- **Košarkaška lopta u dodiru s rukama igrača** – označena kao *ballhand*, predstavlja košarkašku loptu koja se detektira u kadru i dodiruje se s rukama igrača.
- **Koš** – označen kao *net*, predstavlja košarkaški obruč s mrežicom koji se detektira u kadru.

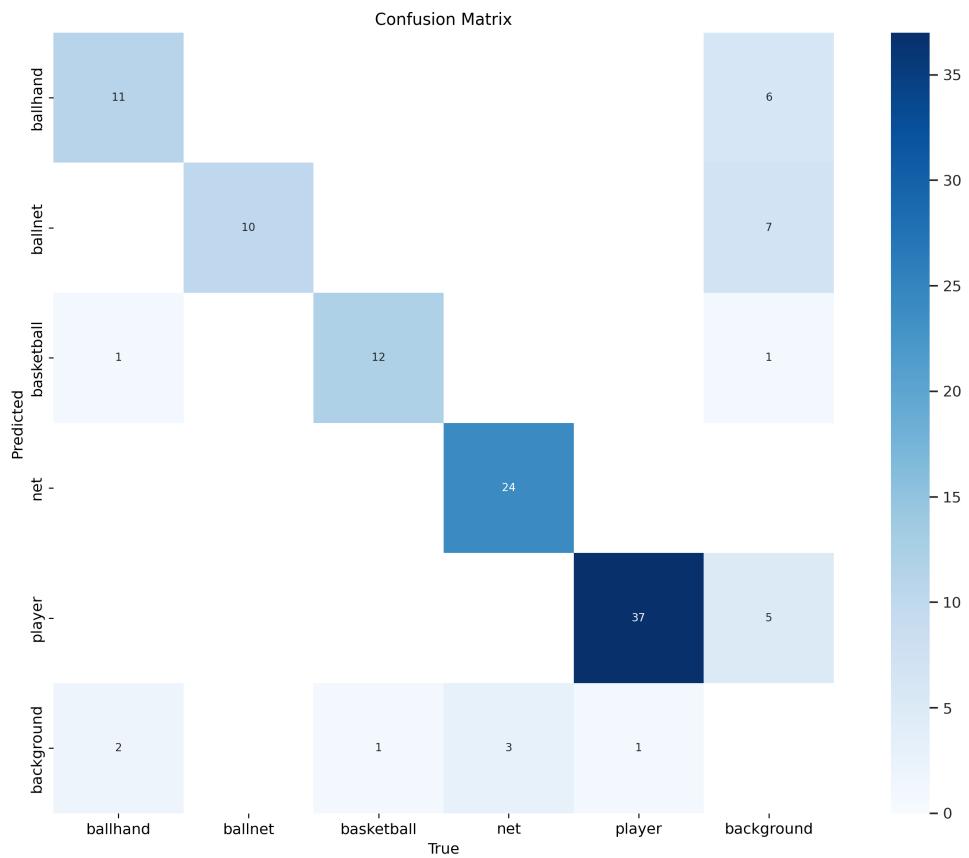
Ove klase omogućuju modelu da razlikuje različite faze šuterskog pokušaja, što je ključno za preciznu analizu izvedbe. Ukupno je prikupljeno i anotirano 185 slika, 70% korišteno je za treniranje modela, 20% za validaciju i 10% za testiranje.

## 4.2. Detekcija objekata korištenjem YOLO modela

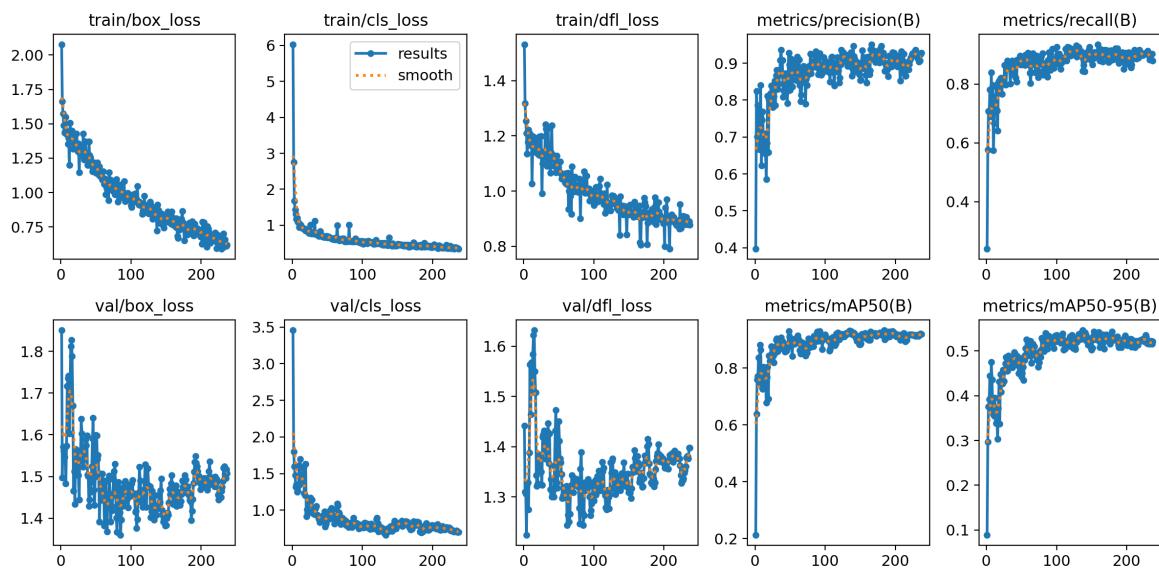
Za detekciju relevantnih objekata korišten je YOLOv11 model, koji je treniran na pretvodno pripremljenom skupu podataka. Anotirani skup slika izvezen je u YOLO format, tj. za svaku sliku spremnjena je datoteka s istim imenom koja sadrži koordinate bounding boxova i pripadajuće klase objekata.

Trening modela proveden je u Google Colabu, koristeći GPU resurse za ubrzanje procesa. Evaluacija modela napravljena je analizom konfuzijske matrice i promatranjem metrika kroz epohu treniranja.

Kao što prikazuje slika 4.1., model najbolje klasificira objekte player i net, dok dočekuje zamjenu kod vizualno sličnih klasa poput ballhand i ballnet. Rezultati treniranja (slika 4.2.) ukazuju na stabilan pad funkcije gubitka i visoku preciznost ( $mAP50 \approx 0.9$ ), što potvrđuje učinkovitost modela na zadatom problemu.



**Slika 4.1.** Konfuzijska matrica detekcijskog modela za šest različitih klasa



**Slika 4.2.** Kretanje funkcije gubitka i metrika tijekom procesa treniranja modela

## 4.3. Prepoznavanje pokušaja šuta i pogodjenih koševa

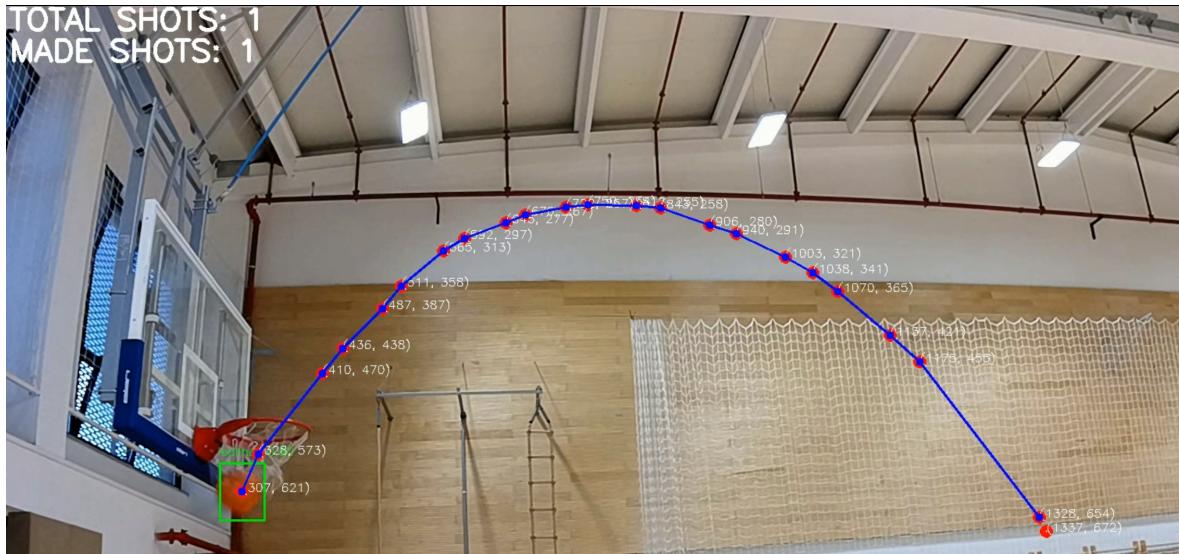
Nakon što je model treniran, sljedeći korak bio je implementacija sustava za prepoznavanje pokušaja šuta i pogodjenih koševa.

Krenimo prvo s prepoznavanjem pokušaja šuta. U svakom kadru bilježe se detektirani objekti. Kada se u istom kadru detektira lopta(basketball) i koš(net), provjeravamo je li centroid bounding boxa lopte unutar zadanog radiusa od centroma bounding boxa koša. Ako je to slučaj, još moramo provjeriti je li lopta iznad koša, tj. je li y koordinata centra lopte veća od y koordinata centra koša. Ako su oba uvjeta zadovoljena, tada se taj kadar smatra pokušajem šuta. Primjer prepoznatog pokušaja šuta prikazan je na slici 4.3.



Slika 4.3. Primjer prepoznatog pokušaja šuta, detektirana lopta i koš su označeni bounding boxovima.

Uspješan šut, tj. pogodak u koš, prepoznaće se na sljedeći način. U slučaju dodira lopte s košem detekcija lopte može biti otežana zbog zaklonjenosti, iz tog razloga koristimo klasu ballnet. Kada detektiramo ballnet u više od dva kadra, tada se smatra da je lopta pogodila koš te bilježimo pogodak. Na slici 4.4. možemo vidjeti trenutak uspješnog šuta.



**Slika 4.4.** Primjer uspješnog šuta, gdje je lopta detektirana u dodiru s košem.

## 4.4. Rekonstrukcija 2D i 3D putanje lopte

Za svaki kadar iz videa, pomoću YOLOv11 modela, detektiraju se bounding boxovi za klase basketball, ballhand, ballnet i net. Iz koordinata bounding boxova lopte, u sve tri varijacije, računamo centroid lopte koji predstavlja sredinu lopte u 2D prostoru slike:

$$C_x = \frac{x_1 + x_2}{2}, \quad C_y = \frac{y_1 + y_2}{2} \quad (4.1)$$

gdje su  $C_x$  i  $C_y$  koordinate centroida, a  $(x_1, y_1)$  i  $(x_2, y_2)$  su koordinate gornjeg lijevog i donjeg desnog kuta bounding boxa lopte. Sve detekcije lopte bilježe se u listu koja se resetira nakon svakog prepoznatog pokušaja šuta i njegove obrade.

Svakim prepoznavanjem klase ballhand zapisujemo koordinate centroida kao početnu točku putanje lopte. Prepoznavanje pokušaja šuta, opisano u prethodnom poglavljju, služi nam kao okidač da se dogodio pokušaj šuta. U tom trenutku, prolaskom kroz listu svih pozicija lopte, tražimo zadnji kadar u kojem je detektirana klasa ballhand, tj. lopta u dodiru s rukama igrača. Taj kadar predstavlja trenutak kada je lopta napustila ruke igrača i počela svoj put prema košu. Od tog kadra počinjemo bilježiti putanju lopte. Detekcije s pragom pouzdanosti (eng. confidence) manjim od 0.8 se ne uzimaju u obzir, čime se filtriraju potencijalne pogreške detekcije (slike ??). Također, postoji uvjet kojim provjeravamo koliko je frameova prošlo od zadnjeg pokušaja šuta čime osiguravamo da

se isti pokušaj obrađuje samo jednom.

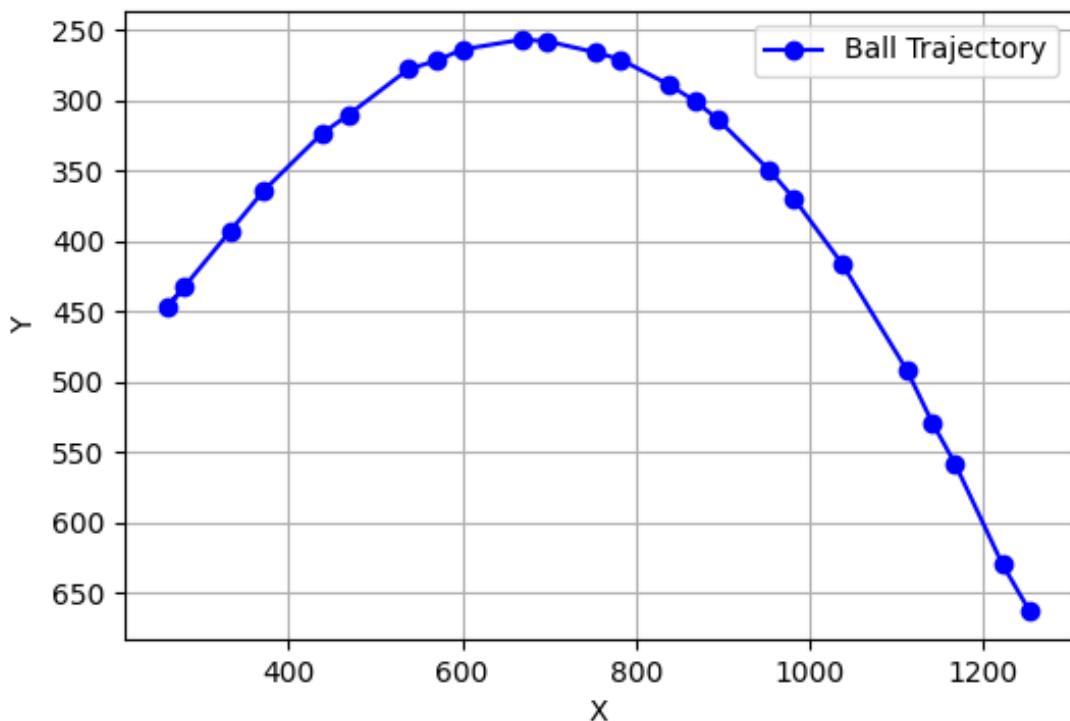


**Slika 4.5.** Pogrešna detekcija klase ballhand koja stvara probleme u rekonstrukciji putanje lopte



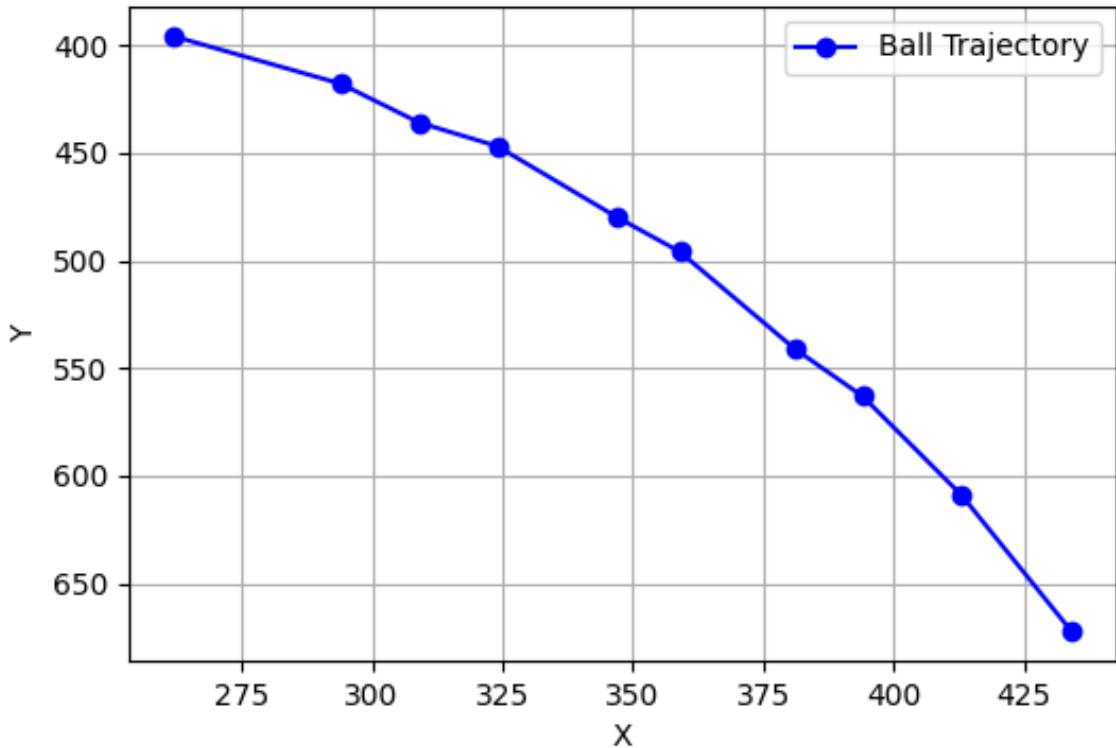
**Slika 4.6.** Zbog pogrešne detekcije lopte, putanja lopte nije točno rekonstruirana

Nakon što se završi prikupljanje podataka o pozicijama lopte tijekom šuterskog pokušaja, moguće je vizualizirati njenu putanju u 2D prostoru slike. Za tu svrhu koristi se biblioteka matplotlib, konkretno modul pyplot, kojim se iz detektiranih i filtriranih centroida lopte crta linija koja prati gibanje lopte tijekom vremena. Takva vizualizacija omogućuje jasan uvid u oblik šuterske putanje, usporedbu između različitih pokušaja, kao i identifikaciju potencijalnih pogrešaka u detekciji (npr. nagli skokovi ili prekidi u kontinuitetu putanje). Osim što služi za analizu, ovakva grafička reprezentacija može se koristiti i za prezentaciju rezultata krajnjem korisniku, odnosno igraču ili treneru. Primjer jedne uspješne vizualizacije putanje može se vidjeti na slici 4.7.



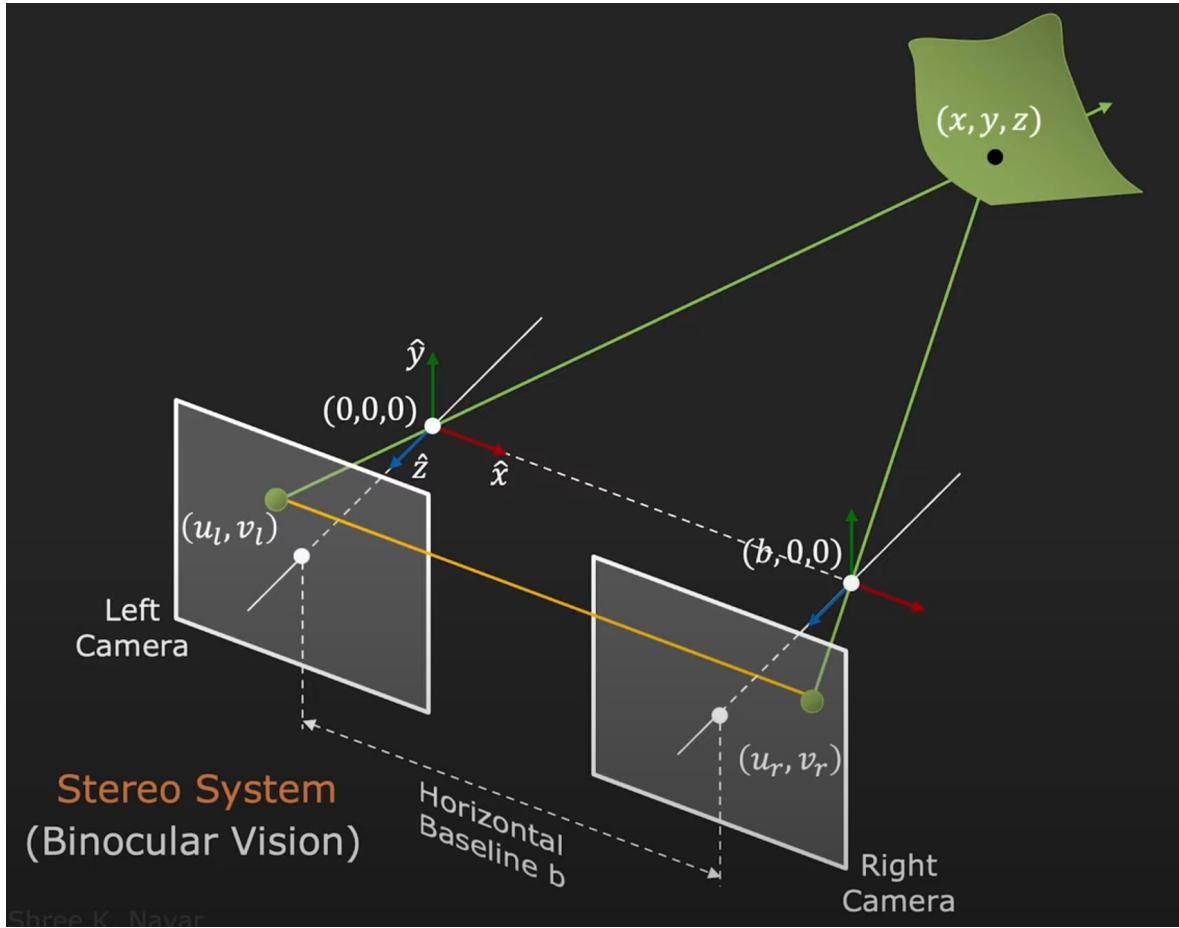
**Slika 4.7.** Primjer vizualizacije putanje lopte u ravnini

Praćenje putanje lopte u 2D prostoru može biti korisno isključivo ako je kamera postavljena okomito na ravninu šuta. U tom slučaju, prikazana putanja približno odgovara stvarnoj fizičkoj putanji lopte. Međutim, u stvarnim uvjetima snimanja, kamera je najčešće postavljena pod kutom ili blago izvan linije šuta, što rezultira značajnom perspektivnom distorzijom, kao što se vidi na primjeru putanje na slici 4.8.



Slika 4.8. Primjer vizualizacije putanje lopte u ravnini s perspektivnom distorzijom

U takvim slučajevima 2D prikaz više ne nudi precizne informacije o stvarnoj putanji, jer nedostaje informacija o dubini (udaljenosti lopte od kamere). To otežava analizu izbačaja, identifikaciju tehničkih grešaka te mogućnost usporedbe različitih pokušaja iz različitih pozicija. Zbog toga je bilo nužno proširiti analizu u 3D prostor, tako da se uz položaj lopte u ravnini slike ( $x, y$ ) koristi i njegova dubinska koordinata ( $z$ ). Ta se vrijednost dobiva pomoću depth mape generirane OaAK-D Pro stereo kamerom. Ova kamera radi tako da se ista 3D točka projicira na dvije leće (lijevu i desnu). Razlika u pozicijama projekcija nazivamo disparity, a pomoću poznate udaljenosti između leća (baseline) moguće je izračunati dubinu točke triangulacijom, princip je opisan slikom 4.9.



**Slika 4.9.** Ilustracija stereo sustava s dvjema kamerama [20]

Za svaki detektirani bounding box lopte, izračunava se centroid, a zatim se u području oko te točke (tipično  $10 \times 10$  piksela) uzimaju vrijednosti iz depth slike. Kao što je opisano u dokumentaciji OpenCV biblioteke [21], za točku na slici sa koordinatama  $(u, v)$  (centar bounding boxa), i poznatom dubinskom vrijednosti  $Z$ , 3D koordinate  $(X, Y, Z)$  računaju se prema sljedećim formulama:

$$X = \frac{(u - c_x) \cdot Z}{f_x}, \quad Y = \frac{(v - c_y) \cdot Z}{f_y}, \quad Z = Z \quad (4.2)$$

gdje su:

$u, v$  – koordinate točke u slici (pikseli),

$Z$  – dubina u metrima,

$f_x, f_y$  – žarišne duljine (focal lengths) kamere izražene u pikselima,

$c_x, c_y$  – koordinate optičkog centra (principal point) slike.

Na taj način za svaki kadar snimke dobivamo točnu 3D poziciju lopte, a spajanjem tih točaka kroz vrijeme moguće je rekonstruirati stvarnu putanju lopte u odnosu na koš i okolinu . Ta putanja se potom može koristiti za detaljnu analizu izbačaja, uključujući izračun kuta i brzine izbačaja lopte.

#### **4.5. Određivanje kuta izbačaja i brzine šuta**

#### **4.6. Mogućnosti prijenosa sustava na mobilne uređaje**

## **5. Rezultati i rasprava**

### **5.1. Primjeri detekcije i analize šuteva**

### **5.2. Evaluacija točnosti detekcije i analize**

- 5.2.1. Eksperimenti u kojima se razvijeni postupak dobro po-naša**
- 5.2.2. Eksperimenti u kojima postupak nalazi objekte koje ni-smo tražili (false positive error)**
- 5.2.3. Eksperimenti u kojima postupak ne pronađe tražene objekte (false negative error)**

## **6. Zaključak**

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

## Literatura

- [1] Šime Kumanović, "Značajnost slobodnih bacanja na strategiju igre i konačan rezultat utakmice", Magistarski rad, Kineziološki fakultet, Sveučilište u Zagrebu, Zagreb, 2006.
- [2] D. Milanović, "Utjecaj varijabli ubacivanja lopte u koš na konačni rezultat košarkaške utakmice." *Kinezilogija*, sv. 8, br. 1-2, str. 136–148, 1978.
- [3] I. Goodfellow, Y. Bengio, i A. Courville, *Deep Learning*. MIT Press, 2016., <http://www.deeplearningbook.org>.
- [4] S. Lončarić, "Neuronske mreže: Višeslojni perceptron", Prezentacija, Fakultet Elektrotehnike i računarstva, 2024.
- [5] B. D. Bašić, M. Čupić, i J. Šnajder, "Umjetna inteligencija: 11. umjetne neuronske mreže", Prezentacija, Sveučilište u Zagrebu, Fakultet elektrotehnike i računarstva, 2020., akademska godina 2019./2020.
- [6] K. N. Haque. (2023) What is convolutional neural network — cnn (deep learning). Accessed: 2025-06-04. [Mrežno]. Adresa: <https://nafizshahriar.medium.com/what-is-convolutional-neural-network-cnn-deep-learning-b3921bdd82d5>
- [7] Chris i Mandy. (2017) Convolutional neural networks (cnns) explained. Accessed: 2025-06-05. [Mrežno]. Adresa: [https://deeplizard.com/learn/video/YRhxdVk\\_sIs](https://deeplizard.com/learn/video/YRhxdVk_sIs)
- [8] R. Kundu. (2023) Yolo algorithm for object detection explained [+examples]. Accessed: 2025-06-05. [Mrežno]. Adresa: <https://www.v7labs.com/blog/yolo-object-detection>

- [9] L. Bastijanić, "Detekcija objekata metodama strojnog učenja", Diplomski rad, Sveučilište Jurja Dobrile u Puli, Fakultet informatike u Puli, 2020., accessed: 2025-06-05. [Mrežno]. Adresa: <https://urn.nsk.hr/urn:nbn:hr:137:616314>
- [10] J. Redmon i A. Farhadi, "Yolov3: An incremental improvement", *arXiv*, 2018.
- [11] V. Kartik i R. Greer, "Optimizing basketball shot trajectory using image segmentation techniques for training feedback", u *2024 IEEE MIT Undergraduate Research Technology Conference (URTC)*, 2024., str. 1–6. <https://doi.org/10.1109/URTC65039.2024.10937574>
- [12] G. Raiola i T. D'isanto, "Descriptive shot analysis in basketball", *Journal of Human Sport and Exercise*, sv. 11, 01 2016. <https://doi.org/10.14198/jhse.2016.11.Proc1.18>
- [13] G. R. Hamilton i C. Reinschmidt, "Optimal trajectory for the basketball free throw", *Journal of Sports Sciences*, sv. 15, br. 5, str. 491–504, listopad 1997. <https://doi.org/10.1080/026404197367137>
- [14] C. M. Tran i L. M. Silverberg, "Optimal release conditions for the free throw in men's basketball", *Journal of Sports Sciences*, sv. 26, br. 11, str. 1147–1155, rujan 2008. <https://doi.org/10.1080/02640410802004948>
- [15] Python, "Python documentation", <https://www.python.org/about/>.
- [16] OpenCV, "OpenCV documentation", <https://docs.opencv.org/4.x/d1/dfb/intro.html>.
- [17] Luxonis, "Oak-D Pro Wide PoE documentation", <https://docs.luxonis.com/hardware/products/OAK-D%20Pro%20W%20PoE>.
- [18] Roboflow, "Roboflow Annotate - Image Labeling Tool", <https://roboflow.com/annotate>, 2024.
- [19] Ultralytics, "Ultralytics YOLOv11 Documentation", <https://docs.ultralytics.com/#how-can-i-train-a-custom-yolo-model-on-my-dataset>, 2024.
- [20] F. P. of Computer Vision, "Simple stereo | camera calibration", <https://www.youtube.com/watch?v=hUVyDabn1Mg&t=423s>, 2021., snimka zaslona.

[21] OpenCV Contributors, “Camera calibration and 3d reconstruction — opencv documentation”, [https://docs.opencv.org/4.x/d9/d0c/group\\_\\_calib3d.html](https://docs.opencv.org/4.x/d9/d0c/group__calib3d.html), accessed: 2025-06-16.

# Sažetak

## **Analiza treninga košarke putem mobilne aplikacije**

Vedran Kumanović

Unesite sažetak na hrvatskom.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

**Ključne riječi:** prva ključna riječ; druga ključna riječ; treća ključna riječ

# **Abstract**

## **Analysis of basketball training through a mobile application**

Vedran Kumanović

Enter the abstract in English.

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

**Keywords:** the first keyword; the second keyword; the third keyword

## **Privitak A: The Code**

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam

rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

  Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

  Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.