

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 1936

**ANALIZA TRENINGA KOŠARKE PUTEM
MOBILNE APLIKACIJE**

Vedran Kumanović

Zagreb, lipanj, 2025.

Zagreb, 3. ožujka 2025.

ZAVRŠNI ZADATAK br. 1936

Pristupnik: **Vedran Kumanović (1191247427)**
Studij: Elektrotehnika i informacijska tehnologija i Računarstvo
Modul: Računarstvo
Mentor: izv. prof. dr. sc. Matko Orsag

Zadatak: **Analiza treninga košarke putem mobilne aplikacije**

Opis zadatka:

Cilj ovog rada je razviti mobilnu aplikaciju za analizu i poboljšanje košarkaškog treninga te istražiti mogućnosti primjene postojećih i razvoj novih perifernih uređaja povezanih putem Bluetooth tehnologije. Aplikacija će omogućiti prikupljanje i analizu podataka o igračevim performansama, poput preciznosti šuta i kretanja na terenu. Istražit će se mogućnosti integracije s pametnim senzorima, nosivim uređajima i drugim Bluetooth dodacima kako bi se poboljšala interaktivnost i preciznost mjerenja.

Rok za predaju rada: 23. lipnja 2025.

Hvala svima koji su mi pomogli u radu na ovom završnom radu.

Sadržaj

1. Uvod	3
2. Teorijska podloga i dosadašnja istraživanja	5
2.1. Umjetne neuronske mreže	5
2.1.1. Višeslojni perceptron	6
2.1.2. Konvolucijske neuronske mreže	7
2.2. Detekcija objekata	9
2.2.1. Dvostupanjske metode detekcije objekata	9
2.2.2. Jednostupanjske metode detekcije objekata	10
2.3. Dosadašnja istraživanja	11
3. Korištene tehnologije i alati	12
4. Razvoj sustava za detekciju i analizu košarkaškog šuta	13
4.1. Prikupljanje i obrada podataka	13
4.2. Detekcija objekata korištenjem YOLO modela	13
4.3. Prepoznavanje pokušaja šuta i pogođenih koševa	13
4.4. Rekonstrukcija 2D i 3D putanje lopte	13
4.5. Određivanje kuta izbačaja i brzine šuta	13
4.6. Mogućnosti prijenosa sustava na mobilne uređaje	13
5. Rezultati i rasprava	14
5.1. Primjeri detekcije i analize šuteva	14
5.2. Evaluacija točnosti detekcije i analize	14
5.2.1. Eksperimenti u kojima se razvijeni postupak dobro ponaša	14

5.2.2.	Eksperimenti u kojima postupak nalazi objekte koje nismo tražili (false positive error)	14
5.2.3.	Eksperimenti u kojima postupak ne pronalazi tražene objekte (false negative error)	14
6.	Zaključak	15
	Literatura	16
	Sažetak	18
	Abstract	19
	A: The Code	21

1. Uvod

Osnovni cilj košarkaške igre je stvaranje prilika za poentiranje, pri čemu svi elementi individualne tehnike, timske suradnje i kolektivne taktike nastoje omogućiti igraču da dođe u što povoljniju poziciju za šut. Brojna istraživanja pokazala su da učinkovitost šuta, posebice u ključnim trenucima utakmice i s različitih pozicija na terenu, u značajnoj mjeri određuje ishod susreta. Primjerice, u analizama utakmica hrvatske lige pokazano je da slobodna bacanja u posljednjih pet minuta čine u prosjeku 42% poena pobjedničkih ekipa u tijesnim završnicama, u usporedbi s tek 22% kod poraženih [1]. Osim toga, dokazano je da je konačni rezultat utakmice snažno povezan s preciznošću šutiranja s distance, ali i s realizacijom šuteva iz reketa, poput polaganja i zakucavanja [2]. Bez efikasnog poentiranja, svi ostali tehničko-taktički aspekti igre gube smisao.

S obzirom na ova saznanja, jasno je da preciznost šuta, kako iz igre tako i s linije slobodnog bacanja, igra presudnu ulogu u konačnom ishodu košarkaških utakmica. Intenzivan i ponavljajući samostalni trening neophodan je za napredak u šutu, no mnogim igračima nedostaje mogućnost objektivne analize vlastite tehnike. Analize šuterske učinkovitosti te biomehanike izvedbe u većini trenažnih procesa još uvijek se uvelike oslanjaju na subjektivne dojmove trenera i ručne statistike. Takav pristup često je spor, sklon pogreškama i ne omogućuje dublju, kvantitativnu analizu specifičnih šuterskih situacija, kao što su kut i brzina izbačaja lopte.

Cilj ovog rada je razvoj sustava za automatsku analizu šuterske izvedbe u košarci korištenjem računalnog vida i dubinskih kamera. Sustav omogućuje precizno praćenje 3D putanje lopte, detekciju koša te izračun ključnih metrika poput kuta izbačaja, brzine lopte i uspješnosti šuta. Takva analiza pruža trenerima i igračima objektivne informacije potrebne za optimizaciju trenažnog procesa i povećanje učinkovitosti.

Za detekciju lopte i obruča koristi se unaprijed istreniran YOLO model, dok se 3D pozicije objekata dobivaju kombiniranjem 2D koordinata s dubinskim informacijama. Razvijeni sustav predstavlja korak prema modernizaciji trenažnog procesa u košarci, omogućujući preciznu, automatiziranu i pristupačnu analizu šuta, s ciljem poboljšanja individualne izvedbe i ukupne uspješnosti momčadi.

2. Teorijska podloga i dosadašnja istraživanja

2.1. Umjetne neuronske mreže

Duboko učenje temelji se na sposobnosti neuronskih mreža da aproksimiraju složene nelinearne funkcije, što omogućuje njihovu primjenu u širokom spektru problema [3]. Ključni model koji se koristi za tu svrhu je višeslojni perceptron (eng. multilayer perceptron (MLP)), koji kroz višeslojne arhitekture modelira odnose između ulaza i željenih izlaza.


Za uspješno treniranje takvih mreža nužno je koristiti tehnike poput regularizacije (za sprječavanje prenaučivosti) i optimizacijskih algoritama (poput varijanti gradijentnog spusta). Kada se modeli primjenjuju na velike ulaze, primjerice slike visoke rezolucije ili vremenske nizove, koriste se specijalizirane arhitekture:

- **Konvolucijske neuronske mreže (CNN)** – dizajnirane za obradu vizualnih podataka, koriste konvolucijske slojeve za automatsko prepoznavanje značajki u slikama.
- **Rekurentne neuronske mreže (RNN)** – koriste se za sekvencijalne podatke, poput teksta ili vremenskih nizova, jer mogu modelirati vremensku ovisnost između podataka.

Ove arhitekture čine temelj za mnoge praktične primjene dubokog učenja, uključujući analizu videozapisa, detekciju objekata i biomehaničku analizu pokreta, što je izravno povezano s temom ovog rada.

2.1.1. Višeslojni perceptron

Duboke unaprijedne mreže (eng. deep feedforward networks), poznate i kao višeslojni perceptroni (MLP – Multilayer Perceptrons), predstavljaju jedan od najvažnijih modela dubokog učenja. Njihov osnovni cilj je aproksimacija nepoznate funkcije f^* , koja opisuje odnos između ulaznih podataka x i željenog izlaza y , odnosno $y=f^*(x)$. Riječ je o vrsti umjetne neuronske mreže sastavljene od niza slojeva međusobno povezanih neuronskih jedinica (perceptrona) 2.1. Ove mreže nazivamo unaprijednim jer se informacije kroz mrežu kreću samo u jednom smjeru, od ulaza prema izlazu, kroz niz skrivenih slojeva i nelinearnih transformacija. Nema povratnih veza između slojeva, za razliku od rekururentnih neuronskih mreža (RNN), kod kojih izlazi mogu ponovno ulaziti u mrežu i time modelirati vremensku ovisnost [3].



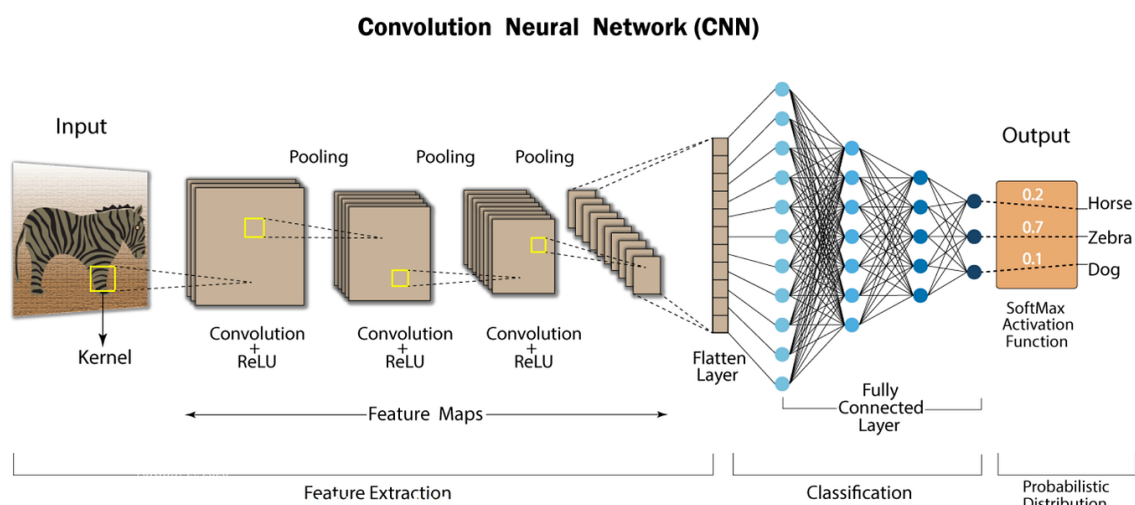
Slika 2.1. Unaprijedna slojevita neuronska mreža $2 \times 3 \times 3 \times 2$ [4]

Da bismo povećali ekspresivnost mreže i omogućili joj modeliranje nelinearnih odnosa, korišteni neuroni moraju imati prijenosne funkcije koje su nelinearne. U unaprijednim neuronskim mrežama do nedavno je bilo uobičajeno koristiti sigmoidalne prijenosne funkcije, dok se danas se za to preferira uporaba ReLU jer omogućava treniranje dubljih mreža (s većim brojem slojeva) [5].

Treniranje MLP mreže provodi se metodom nadziranog učenja, gdje je poznat skup ulazno-izlaznih parova. Učenje neuronskih mreža provodi se pomoću postupka propagacije pogreške unatrag (engl. Error Backpropagation), koji omogućuje učinkovit izračun svih parcijalnih derivacija te njihovu primjenu pri određivanju veličine korekcije svake od težina u mreži [5].

2.1.2. Konvolucijske neuronske mreže


Konvolucijske neuronske mreže (eng. Convolutional Neural Networks - CNN) specijalizirane su vrste neuronskih mreža za obradu podataka koje imaju topologiju nalik na rešetku. Za razliku od višeslojnih perceptrona, gdje su svi neuroni u sloju povezani sa svim neuronima u prethodnom sloju, CNN koristi lokalne veze i dijeljenje težina, čime se značajno smanjuje broj parametara i bolje iskorištava prostorna struktura podataka [3].



Slika 2.2. Arhitektura konvolucijske neuronske mreže [6]

Arhitektura CNN-a, prikazana na slici 2.2., tipično se sastoji od:

- **Konvolucijskih slojeva** – provode operaciju konvolucije nad slikom, pri čemu se filter (jezgra, eng. kernel) sustavno primjenjuje na različite dijelove slike kako bi se prepoznali specifični uzorci ili značajke. Ilustrativni primjer konvolucije možemo vidjeti na slici 2.3. Ulazna slika predstavlja kadar iz videozapisa, konvolucijski filter je matrica vrijednosti koja se pomiče preko slike, a rezultat konvolucije je nova slika koja sadrži informacije o lokalnim značajkama ulazne slike.



Slika 2.3. Primjer konvolucijske operacije koji prepoznaje rubove, najsvjetliji pikseli označavaju detektirani rub. U ovom slučaju to su gornji horizontalni rubovi [7]

- **Slojeva sažimanja (pooling)** – odgovoran je za smanjenje prostorne dimenzionalnosti mapa značajki koje su proizvedene konvolucijskim slojevima (slika 2.4.).



Slika 2.4. Sloj sažimanja, koristi 2×2 matricu [6]

- **Aktivacijskih slojeva** – primjenjuje nelinearnu prijenosnu funkciju na izlaz prethodnog sloja, uobičajeno funkcija ReLU opisana formulom 2.1:

$$ReLU(x) = \max(0, x) \quad (2.1)$$

- **Potpuno povezanih slojeva** – predstavlja klasični sloj umjetnih neuronskih mreža u kojem je svaki neuron povezan sa svim neuronima prethodnog sloja.

Jedna od ključnih prednosti CNN-a je mogućnost hijerarhijskog učenja značajki. Početni slojevi otkrivaju osnovne strukture (npr. rubove), dok dublji slojevi uče složenije

apstrakcije (npr. oblike lopte, ruku ili koša). Upravo zbog toga, CNN modeli su osnova većine modernih sustava za računalni vid, uključujući detekciju objekata, segmentaciju slika i analizu videozapisa.

No ipak, njihova primjena dolazi s određenim izazovima. Treniranje zahtijeva značajne računalne resurse i velike količine podataka zbog složene arhitekture i velikog broja parametara. Osim toga, modeli su skloni prekomjernom učenju na malim skupovima podataka, a njihova interpretabilnost je ograničena jer je teško uvidjeti koje značajke mreža koristi prilikom donošenja odluka. Također, budući da su dizajnirani za podatke rešetkaste strukture, imaju ograničenu sposobnost obrade nepravilnih ili nestrukturiranih oblika.[3, 6].

2.2. Detekcija objekata

Detekcija objekata ključna je zadaća u računalnom vidu koja omogućuje kalsifikaciju i lokalizaciju objekata unutar slike ili videozapisa. Za razliku od klasifikacije slike, koja određuje prisutnost objekta bez navođenja njegove lokacije, detekcija objekta pruža dodatne informacije o poziciji objekta putem koordinata ograničavajućih okvira (bounding boxes) [8].

Metode detekcije objekata mogu se podijeliti u dvije osnovne klase: jednostupanjske (eng. one-stage) i dvostupanjske (eng. two-stage) metode. Dvostupanjske metode detekcije najprije izdvajaju potencijalne regije s objektima, a zatim ih naknadno klasificiraju, dok jednostupanjski pristupi istovremeno obavljaju i lokalizaciju i klasifikaciju objekata. Glavna razlika između ova dva pristupa očituje se u brzini izvođenja – jednostupanjske metode su znatno brže. S druge strane, kada je riječ o preciznosti, obje kategorije postižu usporedive rezultate. U nastavku su detaljnije prikazane obje skupine metoda duboke detekcije objekata [9].

2.2.1. Dvostupanjske metode detekcije objekata


Dvostupanjski pristupi detekciji objekata obavljaju zadatak u više koraka. U prvom koraku, iz ulazne slike se izdvajaju potencijalne regije koje bi mogle sadržavati objekte. Nakon toga, za svaku od tih regija provodi se klasifikacija pomoću prethodno naučenog

klasifikatora, kojim se regije svrstavaju u odgovarajuće klase objekata. Prednost ovih metoda leži u tome što se klasifikacija provodi samo nad ograničenim brojem relevantnih prijedloga, čime se smanjuje utjecaj pozadine i povećava preciznost. Među najpoznatijim predstavnicima ovakvog pristupa su RCNN, SPPnet, Fast RCNN i Faster RCNN. RCNN modeli proširuju standardne konvolucijske mreže za potrebe detekcije i lokalizacije objekata, pri čemu kao izlaz daju skup bounding boxova za svaki detektirani objekt zajedno s pripadajućom klasom [8, 9].

2.2.2. Jednostupanjske metode detekcije objekata

Jednostupanjski algoritmi za detekciju objekata analiziraju cijelu sliku u jednom prolazu kroz mrežu te istovremeno predviđaju prisutnost i lokaciju objekata. Ovakav pristup značajno je učinkovit u pogledu računalnih resursa i brzine izvođenja, što ga čini pogodnim za primjenu u sustavima s ograničenim hardverskim kapacitetima i u stvarnom vremenu. Najpoznatije metode ovog tipa su: OverFeat, SSD, YOLO i RetinaNet.

Jedan od najpoznatijih predstavnika ove skupine i metoda koju ćemo mi koristiti je YOLO, koji koristi potpuno konvolucijsku neuronsku mrežu za istovremenu detekciju svih objekata na slici [8]. YOLO algoritam kao ulaz uzima cijelu sliku i koristi jednostavnu duboku konvolucijsku neuronsku mrežu za detekciju objekata. Struktura mreže temeljena je na CNN arhitekturi, koja se sastoji od konvolucijskih slojeva, slojeva sažimanja i potpuno povezanih slojeva (slika 2.5.).



Slika 2.5. Arhitektura CNN modela koji je temelj za YOLO [8]

YOLO model dijeli ulaznu sliku na mrežu ćelija, pri čemu svaka ćelija predviđa odre-

deni broj bounding boxova i pripadajućih vjerojatnosti za prisutnost objekta [10]. Svaka ćelija odgovorna je za detekciju objekata čiji centar leži unutar njezine granice. YOLO model koristi konvolucijske slojeve za ekstrakciju značajki iz slike, a zatim koristi potpuno povezane slojeve za generiranje predikcija[8]. Svaki granični okvir ima predviđanja u obliku (x, y, w, h, s) gdje su (x,y) koordinate okvira unutar ćelije, (w,h) dimenzije graničnog okvira, a „s“ je pouzdanost da se objekt nalazi u okviru [9].

2.3. Dosadašnja istraživanja

3. Korištene tehnologije i alati

4. Razvoj sustava za detekciju i analizu košarkaškog šuta

4.1. Prikupljanje i obrada podataka

4.2. Detekcija objekata korištenjem YOLO modela

4.3. Prepoznavanje pokušaja šuta i pogođenih koševa

4.4. Rekonstrukcija 2D i 3D putanje lopte

4.5. Određivanje kuta izbačaja i brzine šuta

4.6. Mogućnosti prijenosa sustava na mobilne uređaje

5. Rezultati i rasprava

5.1. Primjeri detekcije i analize šuteva

5.2. Evaluacija točnosti detekcije i analize

- 5.2.1. Eksperimenti u kojima se razvijeni postupak dobro ponaša**
- 5.2.2. Eksperimenti u kojima postupak nalazi objekte koje nismo tražili (false positive error)**
- 5.2.3. Eksperimenti u kojima postupak ne pronalazi tražene objekte (false negative error)**

6. Zaključak

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Literatura

- [1] Šime Kumanović, “Značajnost slobodnih bacanja na strategiju igre i konačan rezultat utakmice”, Magistarski rad, Kineziološki fakultet, Sveučilište u Zagrebu, Zagreb, 2006.
- [2] D. Milanović, “Utjecaj varijabli ubacivanja lopte u koš na konačni rezultat košarkaške utakmice.” *Kineziologija*, sv. 8, br. 1-2, str. 136–148, 1978.
- [3] I. Goodfellow, Y. Bengio, i A. Courville, *Deep Learning*. MIT Press, 2016., <http://www.deeplearningbook.org>.
- [4] S. Lončarić, “Neuronske mreže: Višeslojni perceptron”, Prezentacija, Fakultet Elektrotehnike i računarstva, 2024.
- [5] B. D. Bašić, M. Čupić, i J. Šnajder, “Umjetna inteligencija: 11. umjetne neuronske mreže”, Prezentacija, Sveučilište u Zagrebu, Fakultet elektrotehnike i računarstva, 2020., akademska godina 2019./2020.
- [6] K. N. Haque. (2023) What is convolutional neural network — cnn (deep learning). Accessed: 2025-06-04. [Mrežno]. Adresa: <https://nafizshahriar.medium.com/what-is-convolutional-neural-network-cnn-deep-learning-b3921bdd82d5>
- [7] Chris i Mandy. (2017) Convolutional neural networks (cnns) explained. Accessed: 2025-06-05. [Mrežno]. Adresa: https://deeplizard.com/learn/video/YRhxdVk_sIs
- [8] R. Kundu. (2023) Yolo algorithm for object detection explained [+examples]. Accessed: 2025-06-05. [Mrežno]. Adresa: <https://www.v7labs.com/blog/yolo-object-detection>

- [9] L. Bastijanić, “Detekcija objekata metodama strojnog učenja”, Diplomski rad, Sveučilište Jurja Dobrile u Puli, Fakultet informatike u Puli, 2020., accessed: 2025-06-05. [Mrežno]. Adresa: <https://urn.nsk.hr/urn:nbn:hr:137:616314>
- [10] J. Redmon i A. Farhadi, “Yolov3: An incremental improvement”, *arXiv*, 2018.

Sažetak

Analiza treninga košarke putem mobilne aplikacije

Vedran Kumanović

Unesite sažetak na hrvatskom.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Ključne riječi: prva ključna riječ; druga ključna riječ; treća ključna riječ

Abstract

Analysis of basketball training through a mobile application

Vedran Kumanović

Enter the abstract in English.

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Keywords: the first keyword; the second keyword; the third keyword



Slika 6.1. Moja prva slika

Referenciramo se na sliku 6.1. u sredini rečenice, zatim prije zareza 6.1., te zatim na kraju rečenice 6.1. Upravo smo testirali radi li naredba \ref ispravno u slučaju kada nakon nje slijedi točka.

Sada slijedi jedna jednađžba:

$$\int_{-\infty}^{+\infty} f(t) dt = F(\omega) \quad (6.1)$$

Jednađžba (6.1) je moja prva jednađžba koja defnira par $f(t) \circ \longrightarrow F(\omega)$ ili $F(\omega) \bullet \longrightarrow f(t)$.

Privitak A: The Code

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam

rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.